INFORME TÉCNICO · GENERACIÓN DE AUDIO CON IA

Modelos Open Source de Text-to-Audio

Panorama completo de modelos de generación de audio, música y efectos de sonido desde texto disponibles hasta 2026, con enfoque en despliegue local con GPU de 12 GB VRAM.

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

FECHA

Marzo 2026

HARDWARE OBJETIVO

GPU local · 12 GB VRAM

CATEGORÍAS

SFX · Ambiente · Música · Canciones

FUENTES

Hugging Face · arXiv · GitHub

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

Contenido

1. Introducción y contexto 3

2. Clasificación del ecosistema 4

2.1 Modelos de generación de canciones completas 4

2.2 Modelos instrumentales 6

2.3 Modelos de SFX y audio ambiental 7

2.4 Modelos de comprensión musical (no generativos) 9

3. Análisis en profundidad: MAGNeT 10

3.1 Arquitectura no-autoregresiva 10

3.2 Variantes disponibles 11

3.3 Datos de entrenamiento 12

3.4 Uso y código de inferencia 12

3.5 Limitaciones 13

4. Comparativa general 14

5. Recomendaciones por caso de uso 15

6. Referencias 16

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

SECCIÓN 1

Introducción y contexto

La generación de audio a partir de texto ha experimentado un avance significativo entre 2023 y 2026. Lo que antes requería estudios profesionales, editores de audio especializados y librería de samples con licencia, hoy puede producirse en segundos con un prompt en lenguaje natural y una GPU de consumo.

Este informe documenta el ecosistema open source de modelos text-to-audio disponibles hasta marzo de 2026, con especial atención a los modelos adecuados para generación de **efectos de sonido** y **audio de ambiente** en hardware local con **12 GB de VRAM**.

> **Nota importante sobre terminología:** Existen dos grandes categorías que no deben confundirse. Los modelos de *comprensión musical* (como Music Flamingo de NVIDIA) analizan y responden preguntas sobre audio existente, pero no generan audio nuevo. Los modelos de *generación de audio* producen archivos de sonido a partir de descripciones textuales. Este informe se enfoca principalmente en la segunda categoría.

Alcance del informe

Se incluyen únicamente modelos con pesos públicamente disponibles en plataformas como Hugging Face o GitHub. Se excluyen servicios de API propietarios como Suno, Udio o ElevenLabs, aunque se mencionan como referencia de estado del arte comercial.

Hardware de referencia

VRAM DISPONIBLE	PRECISIÓN RECOMENDADA	FRAMEWORK
12 GB	**fp16**	**PyTorch**
GPU local (RTX 3080/4070 Ti o similar)	Reduce VRAM ~50% sin pérdida significativa	+ HuggingFace Transformers / Diffusers

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

SECCIÓN 2

Clasificación del ecosistema

2.1 Modelos de generación de canciones completas (voz + instrumental)

Este grupo genera canciones completas incluyendo voz, letra e instrumentación sincronizada a partir de una descripción de estilo y/o letra en texto.

YuE

Apache 2.0

HKUST · M-A-P · Hugging Face

El modelo open source más comparable a Suno en capacidades. Genera canciones largas con voces e instrumentación sincronizados. Acepta como entrada una descripción de estilo musical y la letra completa. Soporta múltiples idiomas incluyendo español, chino e inglés. Es el único modelo open source de generación de canciones con licencia verdaderamente permisiva (Apache 2.0), permitiendo uso comercial.

Voz + instrumental | Hasta 5 minutos | Multilingual | 24 GB VRAM | Apache 2.0 (uso comercial)

DiffRhythm

Open

NPU-ASLP — Universidad Politécnica del Noroeste de China

Genera canciones completas de hasta 4 minutos 45 segundos con vocales e instrumentales sincronizados en un único proceso de difusión latente. Su característica más destacada es la velocidad: genera un clip en aproximadamente 10 segundos. Utiliza un VAE de audio entrenado sobre material musical y un transformer de difusión para la síntesis.

Voz + instrumental | ~10 segundos de generación | Difusión latente | Hardware moderado

ACE-Step 1.5

Open

ace-step community · Hugging Face

Genera hasta 4 minutos de música vocal en ~20 segundos. Ofrece capacidades avanzadas como clonación de voz a partir de referencia, edición de letras post-generación, remixing y generación separada por pistas (stems). Compatible con ComfyUI para integración en pipelines visuales. Funciona con 8 GB de VRAM, siendo el más accesible de su categoría.

Voz + instrumental | Clonación de voz | ComfyUI compatible | 8 GB VRAM

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

HeartMuLa

Research

Comunidad Hugging Face

Modelo LLM-based con control fino por secciones musicales (intro, verso, coro, bridge, outro). Acepta audio de referencia como condicionamiento de estilo. Incluye un codec de música propio y componentes para alineación audio-texto y reconocimiento de letras. Orientado a investigación y producción controlada.

Control seccional | Audio de referencia | LLM-based

2.2 Modelos de generación instrumental (sin voz)

Estos modelos generan música puramente instrumental desde descripciones textuales. Son ideales para bandas sonoras, música de fondo y loops.

MusicGen (Meta AI)

CC-BY-NC 4.0

Meta FAIR · Publicado 2023

El modelo de generación musical open source más maduro y documentado. Arquitectura transformer single-stage. Disponible en cuatro tamaños (300M, 1.5B, 3.3B parámetros). Soporta condicionamiento melódico: puede continuar o variar a partir de un fragmento de audio proporcionado. Integrado nativamente en la librería HuggingFace Transformers.

300M – 3.3B params | Melody conditioning | HF Transformers nativo | No comercial

Stable Audio Open

CC-BY-NC 4.0

Stability AI · 2024

Basado en difusión latente de audio. Genera audio de alta calidad con control explícito de duración. Especialmente adecuado para generación de loops, samples y efectos sonoros con características tímbricas específicas. Usa un VAE de audio de alta fidelidad.

Difusión latente | Control de duración | Alta calidad | No comercial

AudioCraft (Meta AI)

CC-BY-NC 4.0

Meta FAIR · Framework completo

Framework PyTorch que engloba MusicGen, AudioGen, MAGNeT, EnCodec y Multi-Band Diffusion. No es un modelo único sino un sistema integral para investigación en generación de audio. Permite entrenamiento propio sobre datos personalizados. Es el punto de entrada recomendado para cualquier investigación seria en generación de audio con PyTorch.

Framework completo | Entrenable | EnCodec incluido | No comercial

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

2.3 Modelos de efectos de sonido y audio ambiental

Esta categoría es la más relevante para el caso de uso objetivo: generación de SFX y ambiente de fondo para videojuegos, aplicaciones, cine y podcasts. Los modelos de esta categoría están entrenados específicamente en datasets de efectos de sonido del mundo real.

AudioGen (Meta AI)

MIT (código) / CC-BY-NC (pesos)

Meta FAIR · AudioCraft framework · 2023

El modelo más especializado en efectos de sonido y escenas acústicas del ecosistema open source. Genera audio de ambiente con gran fidelidad a los prompts: lluvia en tejados de metal, pasos en madera, tráfico urbano, multitudes, viento entre árboles, etc. Entrenado sobre AudioSet, BBC Sound Effects, FSD50K y otros datasets de SFX de alta calidad. Disponible en variantes small (300M, ~4 GB VRAM) y medium (1B, ~8 GB VRAM). Forma parte del framework AudioCraft.

SFX especializado | Ambiente acústico | 300M / 1B params | 4–8 GB VRAM | Hasta 30 segundos | 16 kHz

MAGNeT (Meta AI)

CC-BY-NC 4.0

Meta FAIR · ICLR 2024

Modelo no-autoregresivo incluido en AudioCraft. Genera efectos de sonido, audio ambiental y música desde texto usando un transformer enmascarado. A diferencia de los modelos autoregresivos que producen tokens secuencialmente, MAGNeT genera todos los tokens en paralelo, lo que lo hace hasta 7 veces más rápido que MusicGen o AudioGen con calidad comparable. Disponible en variantes de audio (SFX) y música. Se trata en detalle en la Sección 3 de este informe.

No-autoregresivo | 7× más rápido | SFX + música | 6–8 GB VRAM | Rescoring incluido

AudioLDM2

CC-BY-NC 4.0

CVSSP — University of Surrey · 2023

Modelo de difusión latente para generación de audio general (efectos de sonido, ambiente y música). Admite prompts negativos para excluir elementos no deseados del resultado — característica única entre los modelos de esta lista. Usa dos encoders de texto en paralelo (CLAP + Flan-T5) para mejorar la comprensión de prompts descriptivos complejos. Integrado en la librería HuggingFace Diffusers.

Difusión latente | Prompt negativo | CLAP + Flan-T5 | 8–10 GB VRAM (fp16) | HF Diffusers

AudioLDM (v1)

CC-BY-NC 4.0

CVSSP — University of Surrey · 2023

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

Versión original de AudioLDM, más ligera que v2. Misma arquitectura de difusión latente pero con menor carga computacional. Recomendada cuando se prioriza velocidad sobre calidad máxima, o cuando los recursos de VRAM son más limitados. Compatible con HuggingFace Diffusers.

Más ligero que v2 | 6–8 GB VRAM | Rápido

2.4 Modelos de comprensión musical (no generativos)

Esta categoría **no genera audio**. Procesa audio existente y responde preguntas, genera descripciones o analiza características musicales. Se incluye aquí para clarificar la diferencia con los modelos generativos.

Music Flamingo Think (NVIDIA)

No comercial (NVIDIA OneWay)

NVIDIA ADLR · Hugging Face · 2025

Large Audio-Language Model (LALM) de 8B parámetros para comprensión y razonamiento musical. Basado en Audio Flamingo 3 + Qwen2.5-7B. Implementa chain-of-thought para razonamiento paso a paso. Analiza pistas de audio y responde preguntas sobre género, tempo, tonalidad, instrumentación, letra y contexto cultural. No genera audio — su salida es siempre texto.

Solo comprensión | 8B params | Chain-of-thought | Hasta 20 min de audio | No comercial

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

SECCIÓN 3

Análisis en profundidad: MAGNeT

MAGNeT (Masked Audio Generation using Non-Autoregressive Transformers) es el modelo de efectos de sonido más interesante para el caso de uso objetivo por su combinación de velocidad, calidad y requisitos de hardware moderados. Fue presentado en ICLR 2024 por Meta FAIR y está disponible dentro del framework AudioCraft.

3.1 Arquitectura no-autoregresiva

La innovación central de MAGNeT es su enfoque de generación **no-autoregresivo**. Para entender la diferencia, conviene compararla con los modelos tradicionales:

Característica	Autoregresivo (MusicGen, AudioGen)	No-autoregresivo (MAGNeT)
Generación	Token por token, en secuencia	Todos los tokens en paralelo
Velocidad	Lenta (proporcional a longitud)	~7× más rápida
Dependencia temporal	Alta coherencia temporal	Coherencia mediante rescoring
Calidad	Alta	Comparable con rescoring activo
VRAM	Mayor (estado KV-cache)	Menor (sin KV-cache secuencial)

El proceso de generación sigue un enfoque de *masked prediction iterativa*:

1. El prompt de texto se codifica con un encoder T5.
2. Los tokens de audio objetivo se inicializan como *enmascarados* (tokens [MASK]).
3. El transformer predice todos los tokens enmascarados en un único forward pass.
4. Se desenmascaran iterativamente los tokens de mayor confianza (N pasos de decodificación).
5. Un módulo de *rescoring* filtra las predicciones de baja calidad usando un modelo externo.
6. EnCodec decodifica los tokens finales a forma de onda de audio.

> **Detalle técnico:** MAGNeT opera sobre los tokens del codec EnCodec de Meta, que representa audio con 4 codebooks jerárquicos a 50 tokens por segundo. Esto significa que 30 segundos de audio equivalen a ~6.000 tokens, todos predichos en paralelo en lugar de secuencialmente.

3.2 Variantes disponibles

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

Variante	Modelo HF	Params	VRAM est.	Sample rate	Caso de uso
audio-magnet-small	`facebook/audio-magnet-small`	300M	~4 GB	16 kHz	SFX, ambiente
audio-magnet-medium	`facebook/audio-magnet-medium`	1.5B	~8 GB	16 kHz	SFX, ambiente (mayor calidad)
magnet-small-10secs	`facebook/magnet-small-10secs`	300M	~4 GB	32 kHz	Música instrumental (10 s)
magnet-medium-10secs	`facebook/magnet-medium-10secs`	1.5B	~8 GB	32 kHz	Música instrumental (10 s)
magnet-medium-30secs	`facebook/magnet-medium-30secs`	1.5B	~8 GB	32 kHz	Música instrumental (30 s)

> **Recomendación para 12 GB VRAM:** La variante `audio-magnet-medium` es la más adecuada para el caso de uso de SFX y ambiente. Con 1.5B parámetros ocupa ~8 GB de VRAM, dejando 4 GB de margen para el sistema operativo y otros procesos.

3.3 Datos de entrenamiento (Audio-MAGNeT)

La variante de efectos de sonido fue entrenada con los siguientes datasets:

Dataset	Organización	Descripción	Tamaño
AudioSet	Google	Audio de YouTube con 527 clases de sonido anotadas	~2M clips
BBC Sound Effects	BBC	Librería profesional de efectos de sonido	~16K clips
FSD50K	Freesound / UPF	200 clases de sonido, anotación humana	~51K clips
AudioCaps	UNC Chapel Hill	Subconjunto de AudioSet con captions en texto	~46K clips
Clotho v2	Tampere University	Audio con 5 descripciones textuales por clip	~5K clips
Sonniss Game Effects	Sonniss	Efectos de sonido para videojuegos	~10K clips
WeSoundEffects	Sonniss	Efectos de sonido profesionales adicionales	~3K clips

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

Paramount Odeon Cinematic SFX	Paramount	Efectos cinematográficos de producción	~7K clips

> **Nota sobre voces:** Los tracks vocales de todos los datasets fueron eliminados durante el preprocesamiento usando HT-Demucs antes del entrenamiento. El modelo no genera voces realistas, lo cual es adecuado para casos de uso de SFX y ambiente puro.

3.4 Instalación y código de inferencia

MAGNeT forma parte del framework AudioCraft de Meta y se instala como parte del mismo paquete:

```
pip install audiocraft
```

Ejemplo mínimo de inferencia para efectos de sonido y ambiente:

```
from audiocraft.models import MAGNeT
from audiocraft.data.audio import audio_write

# Cargar el modelo (se descarga automáticamente la primera vez)
model = MAGNeT.get_pretrained("facebook/audio-magnet-medium")

# Definir la duración máxima de generación (segundos)
model.set_generation_params(use_sampling=True, top_k=0, top_p=0.9)

# Lista de prompts descriptivos en inglés
descriptions = [
    "heavy rain on a metal roof with distant thunder rumbling",
    "forest ambience: birds chirping, wind in trees, small stream nearby",
    "busy city street with traffic, car horns and crowd noise",
    "old wooden floor creaking with footsteps in a quiet house",
    "ocean waves crashing on rocky shore, seagulls in the distance",
]

# Generar todos los clips en un solo forward pass
wav = model.generate(descriptions)  # shape: (N, channels, samples)

# Guardar cada clip como archivo WAV
for i, clip in enumerate(wav):
    audio_write(
        f"sfx_clip_{i}",
        clip.cpu(),
        model.sample_rate,
        strategy="loudness",    # normaliza la loudness de salida
        loudness_compressor=True
    )
```

Para uso en batches grandes con control más fino:

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

```python
import torch
from audiocraft.models import MAGNeT
from audiocraft.data.audio import audio_write

# Forzar fp16 para reducir VRAM
device = "cuda" if torch.cuda.is_available() else "cpu"
model = MAGNeT.get_pretrained("facebook/audio-magnet-medium")
model = model.to(torch.float16).to(device)

# Parámetros de generación
model.set_generation_params(
    use_sampling=True,
    top_k=250,
    top_p=0.0,
    temperature=1.0,
    max_cfg_coef=10.0,    # classifier-free guidance strength
    min_cfg_coef=1.0,
    decoding_steps=[20, 10, 10, 10],  # pasos por codebook
    span_arrangement="stride1"
)

prompts = ["wind through pine trees at night", "campfire crackling"]
wav = model.generate(prompts)

for i, audio in enumerate(wav):
    audio_write(f"output_{i}", audio.cpu(), model.sample_rate)
```

3.5 Limitaciones conocidas

Limitación	Descripción	Mitigación
Solo inglés	Entrenado con captions en inglés. Prompts en otros idiomas degradan la calidad.	Traducir prompts al inglés antes de la inferencia.
Máx. 30 segundos	No genera audio de larga duración de manera nativa.	Encadenar clips con crossfade en post-procesado.
Sin voces	No genera habla ni canto realistas.	Combinar con TTS o modelos vocales separados.
16 kHz máx. (SFX)	La variante de audio genera a 16 kHz, no 44.1 kHz.	Upsampling con AudioSR o similar si se requiere mayor calidad.
No comercial	Los pesos están bajo CC-BY-NC. El código fuente es MIT.	Reentrenar sobre datos propios para uso comercial.

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

SECCIÓN 4

Comparativa general

La siguiente tabla resume todos los modelos cubiertos en este informe con sus características más relevantes para el proceso de selección:

Modelo	Tipo	VRAM	SFX	Ambiente	Música	Voz	Velocidad	Licencia
AudioGen medium	AR	~8 GB	✓✓✓	✓✓✓	—	—	Media	CC-BY-NC
MAGNeT medium (audio)	NAR	~8 GB	✓✓✓	✓✓✓	—	—	Alta (7×)	CC-BY-NC
AudioLDM2	Difusión	~10 GB	✓✓✓	✓✓✓	✓✓	—	Media	CC-BY-NC
AudioLDM v1	Difusión	~7 GB	✓✓	✓✓	✓	—	Media-alta	CC-BY-NC
MusicGen large	AR	~12 GB	—	—	✓✓✓	—	Baja	CC-BY-NC
ACE-Step 1.5	Difusión	~8 GB	—	—	✓✓	✓✓✓	Alta	Open
YuE	AR+Difusión	~24 GB	—	—	✓✓	✓✓✓	Baja	Apache 2.0
DiffRhythm	Difusión	Moderado	—	—	✓✓	✓✓✓	Muy alta	Open
Music Flamingo	LALM	~16 GB	—	—	Solo análisis	—	N/A	No comercial

AR = autoregresivo · NAR = no-autoregresivo · LALM = Large Audio-Language Model

SECCIÓN 5

Recomendaciones por caso de uso

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

SFX y ambiente en GPU local de 12 GB VRAM

> **Recomendación principal:** `audio-magnet-medium` + `audiogen-medium` como respaldo.
>
> Usar MAGNeT para generación en tiempo real o batch grande gracias a su velocidad 7× superior. Usar AudioGen cuando se priorice la calidad del resultado sobre la velocidad.

Calidad máxima de SFX (sin restricción de tiempo)

Usar `AudioLDM2` con prompts negativos detallados. El uso de `negative_prompt="music, speech, low quality"` mejora significativamente el resultado para SFX puros.

Música instrumental de fondo

Usar `MusicGen medium` (1.5B, ~8 GB VRAM) con prompts descriptivos. Si se requiere condicionamiento melódico (continuar a partir de un fragmento existente), usar la versión `musicgen-melody`.

Canciones completas con voz

Con 12 GB de VRAM, `ACE-Step 1.5` y `DiffRhythm` son las únicas opciones viables. `YuE` requiere 24 GB y queda fuera del hardware objetivo.

Pipeline combinado recomendado para producción de audio

```
# 1. Ambiente continuo de larga duración
# Generar 30 clips de 30s con MAGNeT y hacer crossfade
model_sfx = MAGNeT.get_pretrained("facebook/audio-magnet-medium")

# 2. Efectos de sonido puntuales
# AudioGen para mayor fidelidad en SFX específicos
model_sfx2 = AudioGen.get_pretrained("facebook/audiogen-medium")

# 3. Música de fondo instrumental
from audiocraft.models import MusicGen
model_music = MusicGen.get_pretrained("facebook/musicgen-medium")

# 4. Upsampling si se necesita calidad CD (44.1 kHz)
# pip install audiosr
from audiosr import super_resolution
upsampled = super_resolution(audio_16khz, input_sr=16000)
```

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF

SECCIÓN 6

Referencias

Papers académicos

Título	Autores	Publicación
Simple and Controllable Music Generation (MusicGen)	Copet et al., Meta FAIR	NeurIPS 2023
Masked Audio Generation using Non-Autoregressive Transformers (MAGNeT)	Ziv et al., Meta FAIR	ICLR 2024
AudioLDM2: Learning Holistic Audio Generation with Self-supervised Pretraining	Liu et al., CVSSP Surrey	TASLP 2024
Music Flamingo: Scaling Music Understanding in Audio Language Models	NVIDIA ADLR	arXiv 2511.10289 · 2025
YuE: Open Music Foundation Models for Full-Song Generation	HKUST · M-A-P	arXiv 2025
DiffRhythm: Blazingly Fast and Embarrassingly Simple Full-Song Generation	NPU-ASLP	arXiv 2025

Repositorios y modelos

Recurso	URL
AudioCraft (Meta)	github.com/facebookresearch/audiocraft
AudioLDM2 (HuggingFace)	huggingface.co/cvssp/audioldm2
Music Flamingo Think (NVIDIA)	huggingface.co/nvidia/music-flamingo-think-2601-hf
YuE	github.com/multimodal-art-projection/YuE
ACE-Step	huggingface.co/ACE-Step
HuggingFace Diffusers	huggingface.co/docs/diffusers/api/pipelines/audioldm2

Informe generado en marzo de 2026. La información sobre modelos, licencias y requisitos de hardware puede cambiar con nuevas versiones. Se recomienda verificar las páginas oficiales de cada modelo antes de cualquier despliegue en producción.

Explore our developer-friendly HTML to PDF API Printed using PDFCrowd HTML to PDF